НИТУ «МИСИС»

Кафедра инженерной кибернетики

ОТЧЕТ

ПО

ЛАБОРАТОРНОЙ РАБОТЕ №8.1

«Разработка программ с поддержкой технологии CUDA

с использованием компилятора командной строки»

учебная дисциплина «Параллельные вычисления»

Студент: Голубев И. М., БПМ-22-ПО-1

Преподаватель: Ватутин Э. И.

Оценка:

Дата защиты: 27.04.2026

2026 г.

Введение

Основная цель работы:

Познакомиться с особенностями разработки программ с использованием технологии CUDA.

Описание решаемой задачи

Разработать следующую программу:

a. Разработать CUDA-ядро для поэлементного сложения векторов;

b. Сформировать вектора из случайных исходных данных;

c. Найти сумму векторов с использованием разработанного CUDA-ядра и с использованием подпрограммы на CPU, сравнить полученные результаты, сделать вывод о корректности расчетов на GPU.

Входные данные

Два массива длины 1024 со значениями, случайно равномерно распределёнными от -100 до +100.

Результат выполнения программы

В ходе выполнения программы должны быть заполнены два массива:

1. Массив, вычисленный на CPU: c_{cpu}

2. Массив, вычисленный на GPU: c_{gpu}

Далее необходимо вычислить ошибку между значениями двух полученных массивов c_{cpu} и c_{gpu}, а затем вывести пользователю значение максимальной ошибки и первые 20 элементов массива, посчитанного на GPU.

Выбранные средства для разработки

Для выполнения лабораторной работы использовались следующие программные средства и технологии:

- Язык программирования: C++17
- Среда разработки: Zed
- Операционная система: Fedora Linux
- Процессор: Intel(R) Core(TM) i5-10300H CPU @ 2.50GHz
- Размер RAM: 15Gi
- Компиляция выполняется средствами утилиты `nvcc`

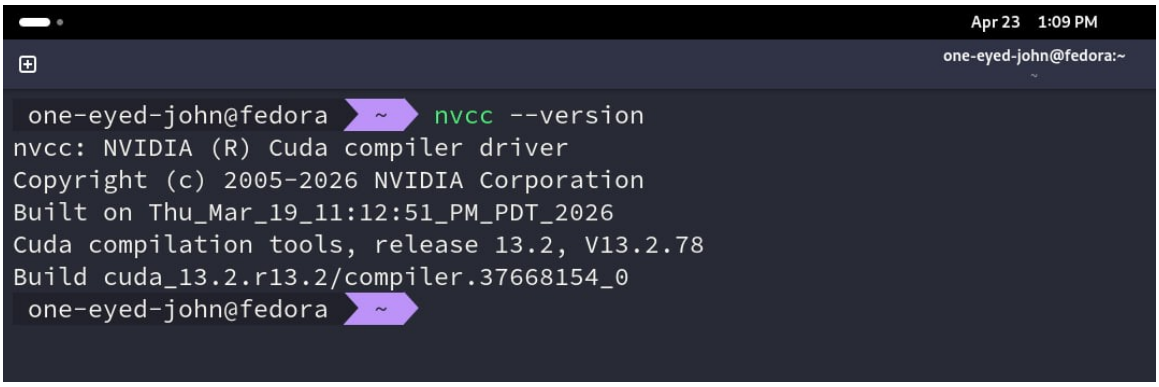

Листинг кода программы

Код доступен в удалённом Github репозитории по ссылке:

https://github.com/g0lubew-iv/parallel-comp/blob/main/lab08/lab08_1.cpp

https://github.com/g0lubew-iv/parallel-comp/blob/main/lab08/lab08_1.cu

Файл lab08_1.cpp

```
#include <iostream>
#include <random>
#include <cmath>

using namespace std;

extern "C" void vec_add_cuda(const float *a, const float *b, float *c, int n);

static void vec_add_cpu(const float *a, const float *b, float *c, int n) {
    for (int i = 0; i < n; i++) {
        c[i] = a[i] + b[i];
    }
}

int main() {
    const int N = 1024;

    float a[N], b[N], c_gpu[N], c_cpu[N];

    std::mt19937 rng(123);
    std::uniform_real_distribution<float> dist(-100.0f, 100.0f);

    for (int i = 0; i < N; i++) {
        a[i] = dist(rng);
```

```
        b[i] = dist(rng);
        c_gpu[i] = 0.0f;
        c_cpu[i] = 0.0f;
    }

    // GPU
    vec_add_cuda(a, b, c_gpu, N);

    // CPU
    vec_add_cpu(a, b, c_cpu, N);

    // compare
    float maxAbsErr = 0.0f;
    int worstIdx = 0;

    for (int i = 0; i < N; i++) {
        float err = std::fabs(c_gpu[i] - c_cpu[i]);
        if (err > maxAbsErr) {
            maxAbsErr = err;
            worstIdx = i;
        }
    }

    cout << "max error |GPU-CPU| = " << maxAbsErr << " at i=" << worstIdx << endl;
    cout << "first 20 GPU results:" << endl;
    for (int i = 0; i < 20; i++) {
        cout << c_gpu[i] << " ";
    }
    cout << endl;

    if (maxAbsErr < 1e-6f)
        cout << "GPU calculations are correct!" << endl;
    else
        cout << "Mismatch detected!" << endl;

    return 0;
}
```

Файл lab08_1.cu

```
#include <cuda.h>
#include <cuda_runtime.h>
#include <cstdio>
#include <cstdlib>

__global__ void VecAddKernel(const float* a, const float* b, float* c, int n) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) {
        c[idx] = a[idx] + b[idx];
    }
}

static void checkCuda(cudaError_t e) {
    if (e != cudaSuccess) {
        std::printf("CUDA error: %s\n", cudaGetErrorString(e));
        std::exit(1);
    }
}

extern "C" void vec_add_cuda(const float *a, const float *b, float *c, int n) {
```

```
    int sizeBytes = n * (int) sizeof(float);

    float *a_gpu = nullptr, *b_gpu = nullptr, *c_gpu = nullptr;

    checkCuda(cudaMalloc((void**)&a_gpu, sizeBytes));
    checkCuda(cudaMalloc((void**)&b_gpu, sizeBytes));
    checkCuda(cudaMalloc((void**)&c_gpu, sizeBytes));

    checkCuda(cudaMemcpy(a_gpu, a, sizeBytes, cudaMemcpyHostToDevice));
    checkCuda(cudaMemcpy(b_gpu, b, sizeBytes, cudaMemcpyHostToDevice));

    dim3 threads(512, 1, 1);
    dim3 blocks((n + threads.x - 1) / threads.x, 1, 1);

    VecAddKernel<<<blocks, threads>>>(a_gpu, b_gpu, c_gpu, n);
    checkCuda(cudaGetLastError());
    checkCuda(cudaDeviceSynchronize());

    checkCuda(cudaMemcpy(c, c_gpu, sizeBytes, cudaMemcpyDeviceToHost));

    cudaFree(a_gpu);
    cudaFree(b_gpu);
    cudaFree(c_gpu);
}
```

Результаты

Сборка и выполнение тестовой программы (первая часть задания):

Сборка и выполнение программы (вторая часть задания):

Выводы

По результатам сравнения расхождения между значениями, полученными на GPU и CPU, не обнаружены. Следовательно, разработанное CUDA-ядро выполняет поэлементное сложение корректно, а перенос вычислений на GPU не приводит к ошибкам в результате.

Для компиляции CUDA-кода на Fedora 41 был установлен CUDA Toolkit (включающий компилятор `nvcc`) из официального репозитория NVIDIA. После установки `nvcc` находился в каталоге `/usr/local/cuda-13.2/bin`, поэтому для корректной работы командной строки путь к нему был добавлен в переменную окружения `PATH` (и при необходимости создан символьный линк `/usr/local/cuda` на установленную версию)

Это обеспечило возможность сборки проекта командой `nvcc <file>.cu <file>.cpp -o <app>`

НИТУ «МИСИС»

Кафедра инженерной кибернетики

ОТЧЕТ

ПО

ЛАБОРАТОРНОЙ РАБОТЕ №8.2

«Определение параметров видеокарты с поддержкой технологии CUDA в среде Microsoft Visual Studio»

учебная дисциплина «Параллельные вычисления»

Студент: Голубев И. М., БПМ-22-ПО-1

Преподаватель: Ватутин Э. И.

Оценка:

Дата защиты: 27.04.2026

2026 г.

Введение и постановка задачи

Основная цель работы:

Определить число видеокарт с поддержкой технологии CUDA и следующие параметры видеокарты:

- наименование;
- общий объем графической памяти;
- объем памяти констант;
- объем разделяемой памяти в пределах блока;
- число регистров в пределах блока;
- размер WARP’а;
- максимально допустимое число потоков в блоке;
- версию вычислительных возможностей;
- число потоковых мультипроцессоров;
- тактовую частоту ядра;
- частоту памяти видеокарты;
- объем кэша второго уровня;
- ширину шины памяти видеокарты;
- максимальную размерность при конфигурации потоков в блоке и блоков в сетке.

Выбранные средства для разработки

Для выполнения лабораторной работы использовались следующие программные средства и технологии:

- Язык программирования: C++17
- Среда разработки: Zed
- Операционная система: Fedora Linux
- Процессор: Intel(R) Core(TM) i5-10300H CPU @ 2.50GHz
- Размер RAM: 15Gi
- Компиляция выполняется средствами утилиты `nvcc`

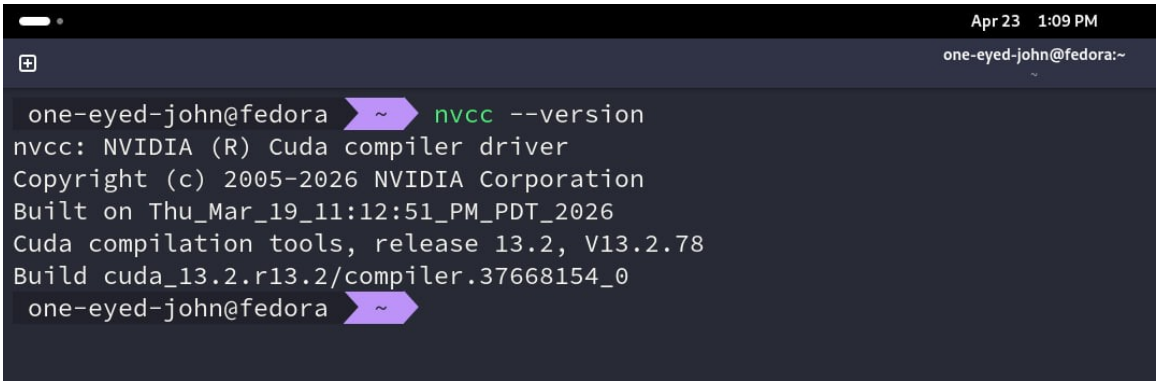

Листинг кода программы

Код доступен в удалённом Github репозитории по ссылке:

https://github.com/g0lubew-iv/parallel-comp/blob/main/lab08/lab08_2.cpp

https://github.com/g0lubew-iv/parallel-comp/blob/main/lab08/lab08_2.cu

Файл lab08_2.cpp

```
extern "C" void print_cuda_device_info();

int main() {
    print_cuda_device_info();
    return 0;
}
```

Файл lab08_2.cu

```
#include <cuda_runtime.h>
#include <cstdio>
#include <cstdlib>
```

```
static void checkCuda(cudaError_t e) {
    if (e != cudaSuccess) {
        std::printf("CUDA error: %s\n", cudaGetErrorString(e));
        std::exit(1);
    }
}

static int getAttr(int dev, cudaDeviceAttr attr) {
    int v = 0;
    checkCuda(cudaDeviceGetAttribute(&v, attr, dev));
    return v;
}

extern "C" void print_cuda_device_info() {
    int count = 0;
    checkCuda(cudaGetDeviceCount(&count));
    std::printf("CUDA devices found: %d\n\n", count);
    if (count == 0) {
        return;
    }

    for (int dev = 0; dev < count; dev++) {
        cudaDeviceProp p{};
        checkCuda(cudaGetDeviceProperties(&p, dev));

        std::printf("Device %d\n", dev);
        std::printf("Name: %s\n", p.name);

        std::printf("Total global memory: %.2f MiB\n",
                    (double)p.totalGlobalMem / (1024.0 * 1024.0));
        std::printf("Constant memory: %.2f KiB\n",
                    (double)p.totalConstMem / 1024.0);
        std::printf("Shared memory per block: %.2f KiB\n",
                    (double)p.sharedMemPerBlock / 1024.0);

        std::printf("Registers per block: %d\n", p.regsPerBlock);
        std::printf("Warp size: %d\n", p.warpSize);
        std::printf("Max threads per block: %d\n", p.maxThreadsPerBlock);

        std::printf("Compute capability: %d.%d\n", p.major, p.minor);
        std::printf("Multiprocessor count (SMs): %d\n", p.multiProcessorCount);

        int coreClockKHz = getAttr(dev, cudaDevAttrClockRate);
        int memClockKHz  = getAttr(dev, cudaDevAttrMemoryClockRate);
        std::printf("Core clock rate: %.2f MHz\n", coreClockKHz / 1000.0);
        std::printf("Memory clock rate: %.2f MHz\n", memClockKHz / 1000.0);

        std::printf("L2 cache size: %.2f KiB\n", (double)p.l2CacheSize / 1024.0);

        std::printf("Memory bus width: %d bits\n", p.memoryBusWidth);

        std::printf("Max threads dim (block): [%d, %d, %d]\n",
                    p.maxThreadsDim[0], p.maxThreadsDim[1], p.maxThreadsDim[2]);
        std::printf("Max grid size: [%d, %d, %d]\n",
                    p.maxGridSize[0], p.maxGridSize[1], p.maxGridSize[2]);
    }
}
```

Результаты

Сборка и выполнение программы (вторая часть задания):

```
one-eyed-john@fedora  ~/Downloads/parallel-comp/lab08  main  nvcc lab08_2.cu lab08_2.cpp -o build/lab08_2

one-eyed-john@fedora  ~/Downloads/parallel-comp/lab08  main  ./build/lab08_2
CUDA devices found: 1

Device 0
Name: NVIDIA GeForce GTX 1650
Total global memory: 3715.69 MiB
Constant memory: 64.00 KiB
Shared memory per block: 48.00 KiB
Registers per block: 65536
Warp size: 32
Max threads per block: 1024
Compute capability: 7.5
Multiprocessor count (SMs): 14
Core clock rate: 1515.00 MHz
Memory clock rate: 6001.00 MHz
L2 cache size: 1024.00 KiB
Memory bus width: 128 bits
Max threads dim (block): [1024, 1024, 64]
Max grid size: [2147483647, 65535, 65535]
one-eyed-john@fedora  ~/Downloads/parallel-comp/lab08  main
```

Выводы

В ходе выполнения задания была разработана программа на CUDA Runtime API для определения числа CUDA-совместимых устройств и получения основных характеристик видеокарты.

В системе обнаружено 1 CUDA-устройство: **NVIDIA GeForce GTX 1650** с вычислительными возможностями Compute Capability 7.5.

Полученные параметры видеокарты: общий объём глобальной памяти — **3716 МБ**, объём константной памяти — **64 КБ**, объём разделяемой памяти на блок — **48 КБ**, число регистров на блок — **65536**, размер warp — **32**, максимально допустимое число потоков в блоке — **1024**.

Число потоковых мультипроцессоров — **14**. Тактовая частота ядра составила **1515 МГц**, частота памяти — **6001 МГц**. Объём кэша L2 — **1024 КБ**, ширина шины памяти — **128 бит**.

Предельные размеры конфигурации: максимальная размерность блока потоков **[1024, 1024, 64]**, максимальная размерность сетки блоков **[2147483647, 65535, 65535]**.

Таким образом, видеокарта корректно определяется CUDA-средой, поддерживает требуемые ограничения по конфигурации запуска и обладает характеристиками, соответствующими модели GTX 1650, что позволяет использовать её для выполнения и отладки CUDA-программ.

НИТУ «МИСИС»

Кафедра инженерной кибернетики

ОТЧЕТ

ПО

ЛАБОРАТОРНОЙ РАБОТЕ №8.3

«Измерение пропускной способности памяти видеокарт

с поддержкой технологии CUDA»

учебная дисциплина «Параллельные вычисления»

Студент: Голубев И. М., БПМ-22-ПО-1

Преподаватель: Ватутин Э. И.

Оценка:

Дата защиты: 27.04.2026

2026 г.

Введение

Основная цель работы:

Научиться измерять пропускную способность памяти GPU при различных типах и направлениях передачи данных.

Описание решаемой задачи

1. Выделить блоки памяти одинакового размера в оперативной памяти и глобальной памяти видеокарты. Скопировать содержимое блоков между:

- двумя буферами в оперативной памяти;

- между оперативной памятью и глобальной памятью видеокарты в направлении CPU GPU и GPU CPU с использованием обычной и page-locked памяти (должно быть 4 различных варианта копирования);

- между двумя буферами в глобальной памяти видеокарты.

2. Убедиться в том, что копирование происходит корректно.

3. Измерить время копирования и, зная размер копируемого блока, определить пропускную способность (в ГБ/с) для каждого типа копирования. Сделать выводы о скорости копирования в различных режимах.

4. В отчет включить краткое описание типа и параметров видеокарты и процессора.

Выбранные средства для разработки

Для выполнения лабораторной работы использовались следующие программные средства и технологии:

- Язык программирования: C++17
- Среда разработки: Zed
- Операционная система: Fedora Linux
- Процессор: Intel(R) Core(TM) i5-10300H CPU @ 2.50GHz
- Размер RAM: 15Gi

- Компиляция выполняется средствами утилиты nvcc

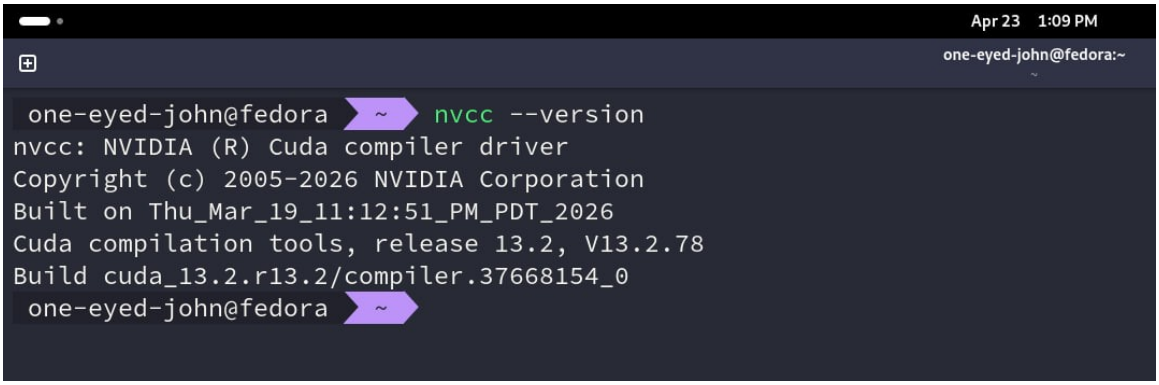

Листинг кода программы

Код доступен в удалённом Github репозитории по ссылке:

https://github.com/g0lubew-iv/parallel-comp/blob/main/lab08/lab08_3.cpp

https://github.com/g0lubew-iv/parallel-comp/blob/main/lab08/lab08_3.cu

Файл lab08_3.cpp

```
#include <iostream>
#include <iomanip>
#include <chrono>
#include <cstring>
#include <vector>
#include <cstdint>

struct Results {
    float h2d_pageable_ms;
    float d2h_pageable_ms;
    float h2d_pinned_ms;
    float d2h_pinned_ms;
    float d2d_ms;

    int ok_h2d_d2h_pageable;
    int ok_h2d_d2h_pinned;
    int ok_d2d;
};

extern "C" Results run_memcpy_bench(size_t bytes, int iters, int do_warmup);

static double gbps(size_t bytes, double ms) {
    return (double)(bytes / 1e9) / (ms / 1000.0);
}

static void cpu_memcpy_bench(size_t bytes, int iters, bool pinned_like, double&
out_ms, bool& ok) {
    std::vector<uint8_t> a(bytes), b(bytes);
    for (size_t i = 0; i < bytes; i++) {
        a[i] = (uint8_t)((i * 17u + 3u) & 0xFF);
    }

    (void) pinned_like;
```

```
    auto t0 = std::chrono::high_resolution_clock::now();
    for (int i = 0; i < iters; i++) {
        std::memcpy(b.data(), a.data(), bytes);
    }
    auto t1 = std::chrono::high_resolution_clock::now();

    std::chrono::duration<double, std::milli> dt = t1 - t0;
    out_ms = dt.count() / iters;
    ok = (std::memcmp(a.data(), b.data(), bytes) == 0);
}

int main(int argc, char** argv) {
    size_t bytes = 256ull * 1024 * 1024; // 256 MiB default

    int iters  = 20;
    int warmup = 1;

    if (argc >= 2) {
        bytes = (size_t)std::stoull(argv[1]); // bytes
    }
    if (argc >= 3) {
        iters = std::stoi(argv[2]); // iterations
    }

    std::cout << "Buffer size: " << bytes << " bytes (" << std::fixed <<
std::setprecision(2) << (bytes / (1024.0*1024.0)) << " MiB)" << std::endl;
    std::cout << "Iterations: "  << iters << std::endl;

    // CPU -> CPU
    double cpu_ms = 0.0;
    bool cpu_ok = false;
    cpu_memcpy_bench(bytes, iters, false, cpu_ms, cpu_ok);

    std::cout << "[CPU->CPU memcpy] avg: " << cpu_ms << " ms, " << gbps(bytes,
cpu_ms) << " GB/s, ok=" << cpu_ok << std::endl;

    // GPU-related copies
    Results r = run_memcpy_bench(bytes, iters, warmup);

    auto pr = [&](const char* name, float ms) {
        std::cout << std::left << std::setw(28) << name
                  << " avg: " << std::right << std::setw(8) << std::fixed <<
std::setprecision(3)
                  << ms << " ms,  "
                  << std::setw(8) << std::setprecision(2) << gbps(bytes, ms)
                  << " GB/s" << std::endl;
    };

    pr("H->D pageable", r.h2d_pageable_ms);
    pr("D->H pageable", r.d2h_pageable_ms);
    std::cout << "  roundtrip ok=" << r.ok_h2d_d2h_pageable << std::endl;

    pr("H->D pinned", r.h2d_pinned_ms);
    pr("D->H pinned", r.d2h_pinned_ms);
    std::cout << "  roundtrip ok=" << r.ok_h2d_d2h_pinned << std::endl;

    pr("D->D", r.d2d_ms);
    std::cout << "  d2d ok=" << r.ok_d2d << std::endl;

    return 0;
}
```

Файл lab08_3.cu

```cpp
#include <cuda_runtime.h>
#include <cstdio>
#include <cstdint>
#include <cstdlib>
#include <cstring>

static void checkCuda(cudaError_t e) {
    if (e != cudaSuccess) {
        std::printf("CUDA error: %s\n", cudaGetErrorString(e));
        std::exit(1);
    }
}

static void fill_pattern(uint8_t* p, size_t n) {
    for (size_t i = 0; i < n; i++) p[i] = (uint8_t)((i * 1315423911u + 12345u) &
0xFF);
}

static bool equal_buf(const uint8_t* a, const uint8_t* b, size_t n) {
    return std::memcmp(a, b, n) == 0;
}

static float gbps(size_t bytes, float ms) {
    return (float)(bytes / 1e9) / (ms / 1000.0f);
}

struct Results {
    float h2d_pageable_ms;
    float d2h_pageable_ms;
    float h2d_pinned_ms;
    float d2h_pinned_ms;
    float d2d_ms;

    int ok_h2d_d2h_pageable;
    int ok_h2d_d2h_pinned;
    int ok_d2d;
};

extern "C" Results run_memcpy_bench(size_t bytes, int iters, int do_warmup) {
    Results r{};
    r.ok_h2d_d2h_pageable = 0;
    r.ok_h2d_d2h_pinned   = 0;
    r.ok_d2d              = 0;

    uint8_t* h_src = (uint8_t*)std::malloc(bytes);
    uint8_t* h_dst = (uint8_t*)std::malloc(bytes);
    uint8_t* h_chk = (uint8_t*)std::malloc(bytes);
    if (!h_src || !h_dst || !h_chk) {
        std::printf("malloc failed\n");
        std::exit(1);
    }

    uint8_t *hp_src = nullptr, *hp_dst = nullptr, *hp_chk = nullptr;
    checkCuda(cudaMallocHost((void**)&hp_src, bytes));
    checkCuda(cudaMallocHost((void**)&hp_dst, bytes));
    checkCuda(cudaMallocHost((void**)&hp_chk, bytes));

    uint8_t *d_a = nullptr, *d_b = nullptr;
    checkCuda(cudaMalloc((void**)&d_a, bytes));
```

```
    checkCuda(cudaMalloc((void**)&d_b, bytes));

    fill_pattern(h_src, bytes);
    std::memset(h_dst, 0, bytes);
    std::memset(h_chk, 0, bytes);

    fill_pattern(hp_src, bytes);
    std::memset(hp_dst, 0, bytes);
    std::memset(hp_chk, 0, bytes);

    // events
    cudaEvent_t e0, e1;
    checkCuda(cudaEventCreate(&e0));
    checkCuda(cudaEventCreate(&e1));

    auto timeMemcpy = [&](cudaMemcpyKind kind, const void* src, void* dst, float*
out_ms) {
        // warmup
        if (do_warmup) {
            checkCuda(cudaMemcpy(dst, src, bytes, kind));
            checkCuda(cudaDeviceSynchronize());
        }
        checkCuda(cudaEventRecord(e0));
        for (int i = 0; i < iters; i++) {
            checkCuda(cudaMemcpy(dst, src, bytes, kind));
        }
        checkCuda(cudaEventRecord(e1));
        checkCuda(cudaEventSynchronize(e1));

        float ms = 0.0f;
        checkCuda(cudaEventElapsedTime(&ms, e0, e1));
        *out_ms = ms / iters;
    };

    timeMemcpy(cudaMemcpyHostToDevice, h_src, d_a, &r.h2d_pageable_ms);
    timeMemcpy(cudaMemcpyDeviceToHost, d_a, h_dst, &r.d2h_pageable_ms);

    r.ok_h2d_d2h_pageable = equal_buf(h_src, h_dst, bytes) ? 1 : 0;

    timeMemcpy(cudaMemcpyHostToDevice, hp_src, d_a, &r.h2d_pinned_ms);
    timeMemcpy(cudaMemcpyDeviceToHost, d_a, hp_dst, &r.d2h_pinned_ms);

    r.ok_h2d_d2h_pinned = equal_buf(hp_src, hp_dst, bytes) ? 1 : 0;

    if (do_warmup) {
        checkCuda(cudaMemcpy(d_b, d_a, bytes, cudaMemcpyDeviceToDevice));
        checkCuda(cudaDeviceSynchronize());
    }
    checkCuda(cudaEventRecord(e0));
    for (int i = 0; i < iters; i++) {
        checkCuda(cudaMemcpy(d_b, d_a, bytes, cudaMemcpyDeviceToDevice));
    }
    checkCuda(cudaEventRecord(e1));
    checkCuda(cudaEventSynchronize(e1));
    float d2d_ms = 0.0f;
    checkCuda(cudaEventElapsedTime(&d2d_ms, e0, e1));
    r.d2d_ms = (d2d_ms / iters);

    checkCuda(cudaMemcpy(h_chk, d_b, bytes, cudaMemcpyDeviceToHost));
    r.ok_d2d = equal_buf(h_chk, h_src, bytes) ? 1 : 0;

    checkCuda(cudaEventDestroy(e0));
```

```
    checkCuda(cudaEventDestroy(e1));

    cudaFree(d_a);
    cudaFree(d_b);

    cudaFreeHost(hp_src);
    cudaFreeHost(hp_dst);
    cudaFreeHost(hp_chk);

    std::free(h_src);
    std::free(h_dst);
    std::free(h_chk);

    return r;
}
```

Результаты

Сборка и выполнение программы:

Выводы

- Во всех рассмотренных режимах копирования (CPU↔CPU, CPU↔GPU, GPU↔GPU) корректность подтверждена: данные после копирования совпадают с исходными (ok=1). Это означает, что выделение памяти и операции memcpy/cudaMemcpy выполнены правильно.

- Копирование между **оперативной памятью и глобальной памятью GPU** с использованием обычной (pageable) host-памяти показывает сравнительно низкую пропускную способность (≈6.3–6.5 GB/s в обоих направлениях). Это связано с тем, что pageable-память требует дополнительных действий со стороны драйвера (в т.ч. использование промежуточных буферов), что увеличивает накладные расходы.

- Использование **page-locked (pinned) памяти** существенно ускоряет обмен CPU↔GPU: пропускная способность выросла примерно до 13 GB/s, то есть примерно в 2 раза по сравнению с pageable-памятью. Следовательно, pinned-память является предпочтительной для интенсивного обмена данными между CPU и GPU.

- Копирование **между двумя буферами в глобальной памяти видеокарты (Device→Device)** оказалось самым быстрым (примерно 72 GB/s), что ожидаемо, так как операция выполняется внутри подсистемы памяти GPU и не ограничена пропускной способностью шины PCIe.

- Копирование **CPU→CPU** показало скорость порядка 9.6 GB/s и служит ориентиром для производительности подсистемы оперативной памяти; при этом скорость обмена CPU↔GPU ограничивается в основном интерфейсом подключения видеокарты и типом host-памяти.